

# 面向 AGI4S 的 Sci-Evo 科学演化 数据构建

---

从文献解析到可训练数据的自动化流水线

 团队

2026-05-29

# 赛题背景与问题定义

## ⚠️ 传统数据痛点

- **静态知识冗余**：现有数据集多侧重于最终结论，缺乏对科研探索过程的记录。
- **推理链路断裂**：模型往往只能“背诵”答案，无法理解“问题-实验-修正”的逻辑闭环。
- **决策能力匮乏**：缺乏对科研工具调用、实验方案调整等动态决策行为的训练数据。

## 💡 我们的切入点：Sci-Evo

- ✓ **动态过程建模**：显式记录科学演化路径，将科研过程转化为可学习的轨迹。
- ✓ **全链路追踪**：构建“初始请求 -> 推理轨迹 -> 验证结论”的结构化数据。
- ✓ **AGI4S 导向**：致力于培养模型具备科学家的思维方式，而非单纯的信息检索。

→ 实现从“静态知识”到“动态科学家”的思维转变

# 项目目标与交付物



## 可复现流水线

构建基于 MinerU + Sciverse 的多源文献数据处理自动化流程。



## AI-Ready 数据集

输出高纯度、结构化的 jsonl 数据集，直接适配大模型训练与微调。



## 多学科全覆盖

实现对材料、物理、生物等 8 个以上前沿学科领域的深度覆盖。

## 核心交付物清单

 核心数据集：[scievo\\_multi\\_paper\\_draft.jsonl](#)

 标准规范：数据 Schema + 技术报告 + 来源清单

 数据集切分：[Train](#) / [Valid](#) / [Test](#) 独立集合

# 技术架构总览



**核心优势：**全流程自动化闭环，确保数据生产的高效性、稳定性与可追溯性。

# 数据结构 (Schema) 设计

```
{
  "initial_request": "...", // 科学问题起点
  "trajectory": [ // 多步推理轨迹
    { "step": 1, "thought": "...", "action": "..." }
  ],
  "success_verification": { // 指标与结论
    "metrics": "...", "conclusion": "..."
  },
  "provenance": { // 来源追溯
    "doc_id": "...", "source_span": "..."
  },
  "quality": { "status": "draft", "score": 0.8 }
}
```

## > initial\_request

定义科学问题的边界与研究目标，作为模型推理的逻辑起点。

## 📡 trajectory

记录“思考-行动-观察”的动态轨迹，支持模型学习复杂的科学决策。

## ✓ success\_verification

提供量化的实验指标与科学结论，用于验证推理过程的正确性。

## 🔗 provenance

精确到文档片段的来源追溯，确保数据的可信度与可核查性。

## 设计原则

Schema 稳定性

语义明确性

便于训练与评测

# 数据构建流程 (可复现性)



>\_ 工程质量核心：支持“一键重跑”全流程，确保科研数据严谨复现

## 数据规模与覆盖结果

524

样本总数

131

独立来源


8

学科领域

367/79/78

TRAIN/VAL/TEST

### 学科分布情况 (样本数)



# 质量控制与合规性

## 质量控制策略

### ✓ 自动化 Schema 校验

所有生成的 JSONL 数据必须通过严格的 JSON Schema 验证，确保字段完整性与类型准确性。

### 📄 多维去重机制

结合论文标题、DOI 及内部文档 ID，执行多层级去重，消除冗余信息，提升训练效率。

### 🕒 全链路元数据追溯

每个样本均包含 task\_id 与 source\_span，实现从结构化数据到原始文献的精确溯源。

## ⚖️ 科研合规原则

### 🚫 严禁虚假实验结果

所有数据均基于真实文献解析，不通过 LLM 幻觉生成任何未经证实的实验结论。

### 🔗 来源合法且可追溯

严格遵守文献使用协议，所有数据来源均有据可查，确保科研成果的合法性。

### 🔑 敏感信息脱敏处理

API 密钥、个人身份信息及敏感 Token 严禁进入公开仓库，保障数据安全。



# 样本示例拆解

Record ID: paper\_scv\_xxx.draft.001

## 初始请求

“在特定温度条件下，分析该材料的晶体结构演化过程，并预测其超导临界温度。”

定义科学问题起点与研究目标

## 推理轨迹

Step 1: 检索相关文献中的实验参数设置...

Step 2: 调用模拟工具计算电子态密度分布...

Step 3: 对比不同压力下的能带结构变化...

展示多步推理与工具调用决策

## 验证结论

“实验观测值与模拟结果一致，超导临界温度提升至 150K，验证了压力诱导相变的有效性。”

提供量化指标与最终科学结论

# 与评分维度对齐

| 评分维度        | 本项目对应证据与成果                                                |
|-------------|-----------------------------------------------------------|
| 科学表达与推理     | ✓ 显式多步轨迹建模，记录“思考-行动-观察”闭环，深度支持科学逻辑训练。                     |
| 科学价值与创新     | ✓ 覆盖 8 个前沿学科，首创 Sci-Evo 动态科研链路数据，填补静态知识库空白。               |
| AI-Ready 程度 | ✓ 提供稳定 Schema 规范与标准 JSONL 格式，预设 Train/Valid/Test 切分，即拿即用。 |
| 工程复现能力      | ✓ 全套自动化构建脚本，支持“一键重跑”，保留所有中间态 Markdown 与元数据。               |
| 开放共享精神      | ✓ 完整技术报告、来源清单及代码全透明公开，支持评审专家进行全流程复核。                      |

# 项目亮点与不足

## ★ 项目亮点

### ✓ 完整闭环与规模化

实现了从“流程跑通”到“规模化生产”的完整闭环，工程化程度高，确保了数据产出的稳定性。

### ✘ 多源扩展能力

架构设计具备极强的兼容性，支持快速接入不同来源的文献数据，具备持续增量生产的能力。

### 📄 交付材料齐全

提供完整的 Schema、构建脚本、来源清单及技术报告，极大降低了后续复核与使用的门槛。

## 🔍 当前不足

### ! 样本精修程度

目前部分样本仍处于 Draft 状态，虽然结构完整，但仍需进一步的人工精修以达到最高质量标准。

### ⚖️ 学科分布配平

虽然覆盖了 8 个学科，但各学科间的样本数量仍存在一定差异，未来需进一步优化学科配平。

### ⚠️ 来源质量波动

个别文献来源的解析质量存在波动，需要引入更强大的过滤机制与质量评分系统。

## 下一步计划

01



### 数据优化

- › 持续扩展独立来源
- › 优化学科分布配平

02



### 质量升级

- › 启动核心样本人工审核
- › Draft -> Approved 升级

03



### 深度迭代

- › 增加“失败-修正”逻辑链
- › 提升量化指标质量



长期愿景：构建具备持续迭代能力的 AGI4S 科学演化基石数据

✔ 项目已达到可提交状态

# 构建 AGI4S 科学演化基石数据

---

我们已建立起一套标准化的自动化生产体系，  
致力于为 AGI 时代的科学发现提供高质量的演化数据支撑。

团队 | 2026-05